



دانشگاه ملی مهارت فارس

ارزیابی و مقایسه معماری‌های نوین یادگیری عمیق برای تشخیص تجهیزات حفاظت فردی

**Personal Protective Equipment Detection through Evaluation and Comparison of
Modern Deep Learning Architectures**

پژوهشگر:

ناصر شاهین اکبرآبادی

کارشناسی مهندسی حرفه ای کامپیوتر

استاد راهنما:

سرکارخانم فاطمه جوکار

تابستان 1405

چکیده

استفاده از تجهیزات ایمنی در محیط‌های صنعتی و کارگاهی برای حفظ سلامت و جان کارگران امری کاملاً حیاتی و ضروری است. با وجود تدوین قوانین سخت‌گیرانه ایمنی و بهداشت کار، عدم رعایت پروتکل‌های ایمنی همچنان یکی از دلایل اصلی بروز حوادث ناگوار و تلفات جبران‌ناپذیر محسوب می‌شود. روش‌های سنتی نظارت که عمدتاً مبتنی بر بازرسی‌های دوره‌ای توسط نیروی انسانی هستند، علاوه بر هزینه بالا و زمان‌بر بودن، همواره مستعد خطای انسانی بوده و به هیچ وجه نمی‌توانند پوشش لحظه‌ای و همه‌جانبه‌ای در سایت‌های ساختمانی و صنعتی گسترده ایجاد کنند. در سال‌های اخیر، پیشرفت‌های چشمگیر در حوزه بینایی ماشین و هوش مصنوعی، راهکارهای خودکار و هوشمندی را برای پایش ایمنی محیط کار فراهم کرده‌اند که تحولی بزرگ در این صنعت به شمار می‌رود. این پژوهش با هدف بهبود سیستم‌های نظارتی هوشمند، به ارزیابی و مقایسه جامع پنج مدل پیشرفته در زمینه تشخیص اشیاء می‌پردازد تا کارآمدترین راهکارها برای استقرار در محیط‌های واقعی شناسایی شوند. شبکه‌های مورد بررسی در این مقاله شامل نسخه‌های مختلف از خانواده پرکاربرد یولو از جمله نسخه‌های دهم، یازدهم، دوازدهم و مدل مبتنی بر متن یولو-ورلد و همچنین معماری مدرن مبتنی بر ترانسفورمر بلادرنک هستند. برای انجام این ارزیابی دقیق، یک مجموعه داده گسترده و متنوع از تصاویر محیط‌های کارگاهی شامل کلاس‌های مختلف ایمنی مانند کلاه، ماسک، جلیقه، افراد، مخروط‌های ترافیکی و ماشین‌آلات جمع‌آوری و با دقت بالا حاشیه‌نویسی شده است. مدل‌های مذکور از منظر معیارهای مختلفی همچون دقت، فراخوانی، میانگین دقت متوسط و همچنین هزینه‌های محاسباتی از جمله تعداد کل پارامترها، میزان عملیات ممیز شناور و زمان مورد نیاز برای آموزش به صورت دقیق مورد تحلیل قرار گرفته‌اند. نتایج به‌دست‌آمده نشان می‌دهد که مدل‌های مبتنی بر معماری ترانسفورمر توانایی بسیار بالایی در استخراج ویژگی‌های پیچیده و دستیابی به بالاترین میزان دقت مطلق دارند. با این حال، این شبکه‌ها عموماً نیازمند منابع پردازشی گسترده و زمان طولانی‌تری برای آموزش هستند. در مقابل، برخی از نسخه‌های جدیدتر شبکه‌های پیچشی مانند یولو، تعادل بسیار مطلوبی بین سرعت استنتاج و دقت تشخیص برقرار می‌کنند که آن‌ها را برای پیاده‌سازی بر روی دستگاه‌های لبه با منابع محدود محاسباتی، بسیار مناسب و کاربردی می‌سازد. در نهایت، انتخاب مدل بهینه کاملاً به نیازهای خاص، بودجه سخت‌افزاری و محدودیت‌های زمانی هر پروژه بستگی دارد و این تحقیق راهنمای جامع و مستدلی برای تصمیم‌گیری مهندسان در این زمینه ارائه می‌دهد.

کلمات کلیدی: یادگیری عمیق، تشخیص شیء، تجهیزات حفاظت فردی، بینایی ماشین، شبکه‌های عصبی

مقدمه

در دنیای صنعتی امروز، حفظ ایمنی محیط کار و محافظت از جان کارگران از اهمیت فوق العاده‌ای برخوردار است و سازمان‌ها در سراسر جهان ملزم به رعایت استانداردهای سخت‌گیرانه‌ای در این زمینه هستند. با وجود پیشرفت‌های فناوری و تدوین پروتکل‌های بهداشتی، کارگاه‌های ساختمانی و کارخانجات تولیدی همچنان به عنوان یکی از پرخطرترین محیط‌های کاری شناخته می‌شوند. آسیب‌های فیزیکی ناشی از سقوط اجسام، برخورد با ماشین‌آلات سنگین و استنشاق گازهای سمی تنها بخشی از مخاطراتی است که کارگران را تهدید می‌کند. از این رو، استقرار یک سیستم مدیریت ایمنی کارآمد که بتواند به صورت پیوسته خطرات بالقوه را پایش کند، به یک اولویت استراتژیک برای مدیران تبدیل شده است [1].

حوادث ناشی از کار سالانه خسارات جانی و مالی جبران‌ناپذیری را به صنایع مختلف تحمیل می‌کنند که نیازمند پیشگیری جدی و اتخاذ تدابیر پیشگیرانه است. بر اساس گزارش‌های سازمان بین‌المللی کار، میلیون‌ها حادثه شغلی در هر سال رخ می‌دهد که منجر به از دست رفتن روزهای کاری، پرداخت غرامت‌های سنگین و افت بهره‌وری می‌شود. این هزینه‌های مستقیم و غیرمستقیم، بار مالی سنگینی را بر دوش اقتصاد جهانی قرار می‌دهد که با سرمایه‌گذاری مناسب در زیرساخت‌های ایمنی قابل پیشگیری است. تحلیل داده‌های حوادث نشان می‌دهد که بخش عمده‌ای از این اتفاقات ناگوار ریشه در خطاهای انسانی و بی‌توجهی به اصول اولیه ایمنی در محیط کار دارد [2].

استفاده از تجهیزات حفاظت فردی (PPE) یکی از اصلی‌ترین، ساده‌ترین و در عین حال مؤثرترین راهکارها برای کاهش چشمگیر این خطرات در محیط‌های پرخطر می‌باشد. کلاه‌های ایمنی می‌توانند از ضربات مهلک به سر جلوگیری کنند، در حالی که جلیقه‌های شبرنگ با افزایش دید کارگران در محیط‌های تاریک، خطر تصادف با وسایل نقلیه را به حداقل می‌رسانند. همچنین استفاده از ماسک‌های تنفسی استاندارد در محیط‌های شیمیایی و آلوده، مانع از بروز بیماری‌های حاد و مزمن تنفسی در بلندمدت می‌شود. با این وجود، فراهم کردن این تجهیزات به تنهایی کافی نیست و اطمینان از استفاده مستمر و صحیح آن‌ها توسط کارگران چالش اصلی کارفرمایان است [3].

نظارت مستمر بر استفاده صحیح از تجهیزات ایمنی توسط کارگران، چالشی بزرگ و طاقت‌فرسا برای مدیران ایمنی (HSE) محسوب می‌شود که نیازمند صرف زمان و انرژی فراوان است. بازرسی‌های دستی و سنتی معمولاً به صورت مقطعی و تصادفی انجام می‌شوند و هرگز نمی‌توانند تمامی زوایای یک سایت کارگاهی گسترده را به

طور مداوم و در تمام ساعات کاری پوشش دهند. علاوه بر این، حضور فیزیکی بازرسان ممکن است باعث شود کارگران تنها در زمان حضور ناظران پروتکل‌ها را رعایت کنند و پس از آن مجدداً به رفتارهای نایمن روی آورند. این محدودیت‌ها نشان می‌دهد که اتکا به نیروی انسانی برای پایش صددرصدی محیط، راهکاری ناکارآمد و غیرقابل اعتماد است [4].

از این رو، نیاز به سیستم‌های پایش خودکار که بتوانند به صورت بلادرنگ خطرات را شناسایی کرده و هشدارهای لازم را صادر کنند، به شدت در صنایع مدرن احساس می‌شود. چنین سیستم‌هایی قادرند بدون خستگی، به صورت ۲۴ ساعته و در هفت روز هفته تصاویر دوربین‌های مداربسته را تحلیل کرده و هرگونه تخلف ایمنی را ثبت کنند. این رویکرد هوشمند نه تنها بار کاری تیم‌های بازرسی را کاهش می‌دهد، بلکه با ایجاد یک آرشیو دقیق از تخلفات، به مدیران در شناسایی الگوهای خطرآفرین و برنامه‌ریزی برای آموزش‌های هدفمند کمک می‌کند. اتوماسیون نظارت ایمنی در نهایت منجر به ایجاد فرهنگی پایدار از ایمنی در سراسر سازمان خواهد شد [5].

بینایی ماشین (Computer Vision) به عنوان یکی از شاخه‌های کلیدی و پرکاربرد هوش مصنوعی، راهکارهای نوآورانه‌ای برای حل مسئله نظارت ایمنی ارائه کرده است. این فناوری به رایانه‌ها اجازه می‌دهد تا از تصاویر و ویدیوهای دیجیتال، درکی مشابه با بینایی انسان به دست آورده و اطلاعات معناداری را از آن‌ها استخراج کنند. در محیط‌های صنعتی، دوربین‌های مجهز به بینایی ماشین می‌توانند به عنوان ناظرانی خستگی‌ناپذیر عمل کرده و موقعیت، وضعیت و پوشش کارگران را در هر لحظه تحلیل نمایند. توسعه الگوریتم‌های پردازش تصویر در یک دهه گذشته، زمینه را برای پیاده‌سازی عملی این سیستم‌ها در مقیاس صنعتی فراهم آورده است [6].

با ظهور و بلوغ الگوریتم‌های یادگیری عمیق (Deep Learning)، توانایی سیستم‌های رایانه‌ای در تحلیل تصاویر و تشخیص الگوهای پیچیده به طرز چشمگیری ارتقا یافته است. برخلاف روش‌های سنتی پردازش تصویر که نیازمند استخراج دستی ویژگی‌ها بودند، شبکه‌های یادگیری عمیق می‌توانند به صورت خودکار سلسله‌مراتبی از ویژگی‌ها را از داده‌های خام بیاموزند. این قابلیت، به ویژه در محیط‌های کارگاهی که شرایط نورپردازی، پس‌زمینه و زاویه دید دوربین‌ها بسیار متغیر است، انعطاف‌پذیری فوق‌العاده‌ای به سیستم می‌بخشد. یادگیری عمیق عملاً راه را برای تشخیص دقیق اشیائی مانند کلاه و جلیقه ایمنی حتی در فواصل دور هموار کرده است [7].

شبکه‌های عصبی پیچشی (CNN) سال‌ها به عنوان استاندارد اصلی و بلامنازع برای استخراج ویژگی‌های تصویری و پردازش داده‌های بصری شناخته می‌شدند. این شبکه‌ها با استفاده از فیلترهای پیچشی محلی، قادرند لبه‌ها، بافت‌ها و اشکال را در لایه‌های ابتدایی تشخیص داده و در لایه‌های عمیق‌تر، مفاهیم پیچیده‌تری مانند فرم بدن انسان یا تجهیزات خاص را درک کنند. معماری‌های معروفی نظیر ResNet و EfficientNet نشان دادند که با افزایش عمق شبکه و استفاده از اتصالات باقیمانده، می‌توان به دقت‌های بی‌نظیری در طبقه‌بندی و تشخیص دست یافت. با این حال، شبکه‌های پیچشی کلاسیک معمولاً برای پردازش‌های بلادرنگ با محدودیت‌های سرعتی مواجه بودند [8].

در حوزه تشخیص شیء (Object Detection)، توسعه مدل‌های تک‌مرحله‌ای (One-Stage Detectors) توانست سرعت پردازش را برای کاربردهای بلادرنگ بهینه‌سازی و متحول سازد. پیش از این، مدل‌های دو مرحله‌ای مانند Faster R-CNN ابتدا نواحی مستعد حضور شیء را پیشنهاد می‌دادند و سپس آن‌ها را طبقه‌بندی می‌کردند که فرآیندی کند و زمان‌بر بود. اما مدل‌های تک‌مرحله‌ای کل تصویر را در یک گذر از شبکه تحلیل کرده و به طور همزمان کادرهای محاطی و احتمالات کلاس‌ها را پیش‌بینی می‌کنند. این معماری یکپارچه، امکان پردازش ده‌ها فریم در ثانیه را فراهم کرده و تشخیص سریع تخلفات ایمنی را در ویدیوهای زنده امکان‌پذیر نمود [9].

خانواده الگوریتم‌های یولو (YOLO) به دلیل معماری کارآمد، سرعت بالا و دقت مطلوب خود، همواره در صدر انتخاب‌ها برای پیاده‌سازی در کاربردهای صنعتی بوده‌اند. از نسخه اول تا نسخه‌های مدرن امروزی، این خانواده با معرفی تکنیک‌هایی نظیر اتصالات مسیر متقاطع، توابع زیان پیشرفته و لایه‌های تجمیع ویژگی بهبود یافته، همواره در مرز دانش بینایی ماشین حرکت کرده است. نسخه‌های جدیدتر این مدل به گونه‌ای طراحی شده‌اند که حتی روی سخت‌افزارهای ضعیف‌تر مانند پردازنده‌های تعبیه‌شده نیز خروجی قابل قبولی ارائه دهند. همین ویژگی سبب شده تا محققان صنعتی برای پایش تجهیزات ایمنی توجه ویژه‌ای به مدل‌های یولو داشته باشند [10].

اخیراً، معماری‌های مبتنی بر ترانسفورمر (Vision Transformers) نیز از حوزه پردازش زبان طبیعی وارد پردازش تصویر شده و نتایج خیره‌کننده‌ای ثبت کرده‌اند. مدل‌های تشخیص اشیاء مبتنی بر ترانسفورمر (DETR) با حذف نیاز به الگوریتم‌های پس‌پردازش مانند سرکوب غیربیشینه (NMS)، معماری سیستم‌های تشخیص را ساده‌تر و یکپارچه‌تر کرده‌اند. این شبکه‌ها نشان داده‌اند که در مدیریت اشیاء متراکم و صحنه‌های شلوغ عملکرد بهتری نسبت به شبکه‌های پیچشی متداول دارند. معرفی مدل‌های ترانسفورمر بلادرنگ مانند

RT-DETR گامی بزرگ در جهت استفاده کاربردی از این شبکه‌های سنگین در پردازش‌های آنی به شمار می‌رود [11].

ترانسفورمرها با استفاده از مکانیزم توجه خودکار (Self-Attention)، وابستگی‌های سراسری و زمینه کلی تصویر را به مراتب بهتر از شبکه‌های پیچشی درک و تفسیر می‌کنند. در حالی که فیلترهای CNN تنها به ناحیه کوچکی از تصویر تمرکز دارند، مکانیزم توجه به هر پیکسل اجازه می‌دهد تا با تمامی پیکسل‌های دیگر در تصویر تعامل داشته و ارتباط برقرار کند. این ویژگی به شبکه کمک می‌کند تا مثلاً ارتباط بین حضور یک شخص و قرارگیری کلاه ایمنی بر روی سر او را با دقت بیشتری تشخیص دهد. درک عمیق‌تر از بافت تصویر باعث کاهش خطاهای مثبت کاذب در محیط‌های پیچیده صنعتی می‌شود [12].

با وجود این پیشرفت‌های شگرف، مقایسه دقیق این مدل‌های نوین در شرایط واقعی و با در نظر گرفتن محدودیت‌های سخت‌افزاری همچنان یک مسئله باز و نیازمند بررسی است. در کاربردهای صنعتی، اغلب امکان استفاده از سرورهای ابری گران‌قیمت وجود ندارد و پردازش‌ها باید روی دستگاه‌های لبه (Edge Devices) صورت گیرد. بنابراین، حجم مدل، میزان حافظه مصرفی و تعداد عملیات محاسباتی عواملی تعیین‌کننده در انتخاب الگوریتم نهایی هستند. یک مدل بسیار دقیق که توانایی اجرای بلادرنگ روی دوربین مداربسته را نداشته باشد، در عمل برای نظارت ایمنی غیرقابل استفاده خواهد بود [13].

ظهور مدل‌های صفر-شات (Zero-shot) مانند YOLO-World نیز دریچه جدیدی به سوی تشخیص اشیاء بدون نیاز به آموزش مجدد باز کرده است. این مدل‌ها با ترکیب پردازش زبان طبیعی و پردازش تصویر، قادرند اشیائی را که در طول آموزش ندیده‌اند، صرفاً با دریافت نام آن‌ها به صورت متنی تشخیص دهند. اگرچه این ایده بسیار جذاب و منعطف است، اما دقت آن در مواجهه با اشیاء تخصصی و محیط‌های خاص مانند تجهیزات ایمنی کارگاهی هنوز به طور کامل به اثبات نرسیده است. ارزیابی این مدل‌ها در کنار مدل‌های آموزش‌دیده کلاسیک می‌تواند نقاط قوت و ضعف آن‌ها را روشن سازد [14].

در این مقاله، ما به ارزیابی و مقایسه جامع جدیدترین مدل‌های تشخیص شیء تا سال ۲۰۲۶ برای شناسایی تجهیزات ایمنی می‌پردازیم. هدف اصلی، شناسایی بهترین معماری از نظر توازن میان دقت تشخیص و هزینه‌های محاسباتی برای استفاده در سیستم‌های هوشمند ایمنی است. در بخش‌های بعدی، ابتدا روش‌شناسی پژوهش، مجموعه داده مورد استفاده و معماری شبکه‌ها به تفصیل بیان می‌شود. سپس با ارائه جداول و

نمودارهای تحلیلی، نتایج استقرار این مدل‌ها مورد بحث قرار می‌گیرد و در نهایت توصیه‌های کاربردی برای محققان و مهندسان صنعت ارائه خواهد شد.

روش پیشنهادی

در این بخش از مقاله، ساختار کلی، تنظیمات پیاده‌سازی و جزئیات روش پیشنهادی برای ارزیابی و مقایسه شبکه‌های عصبی در وظیفه تشخیص تجهیزات ایمنی تشریح می‌گردد. برای دستیابی به یک مقایسه منصفانه و علمی، ضرورت دارد که تمامی مدل‌ها در شرایط کاملاً یکسان از منظر داده‌ها، پیش‌پردازش‌ها و بستر سخت‌افزاری آموزش داده شوند. این امر تضمین می‌کند که تفاوت در نتایج نهایی، منحصرأ ناشی از تفاوت در معماری درونی و ذات الگوریتم‌ها باشد. در ادامه، گام‌های اجرایی این پژوهش از آماده‌سازی داده‌ها تا تعریف معیارهای ارزیابی به صورت پیوسته و منسجم ارائه شده است.

اولین گام حیاتی در توسعه و آزمایش هر سیستم یادگیری ماشین توانمند، جمع‌آوری و آماده‌سازی داده‌های مناسب، متنوع و با کیفیت بالا است. بدون در اختیار داشتن تصاویری که بازتاب‌دهنده چالش‌های واقعی محیط‌های صنعتی باشند، مدل‌های آموزش‌دیده در محیط عملیاتی با افت شدید دقت مواجه خواهند شد. شرایطی نظیر نورپردازی نامناسب، هم‌پوشانی اشیاء، تار بودن فریم‌ها به دلیل حرکت سریع و تنوع در شکل و رنگ تجهیزات باید در داده‌ها لحاظ گردد. به همین دلیل، فرآیند ایجاد مجموعه داده با دقت فراوان و با در نظر گرفتن سناریوهای مختلف کارگاهی انجام پذیرفته است.

در این پژوهش از یک مجموعه داده جامع و تخصصی شامل ده کلاس مختلف مرتبط با تجهیزات ایمنی و ابزارهای صنعتی استفاده شده است. این کلاس‌ها به گونه‌ای انتخاب شده‌اند که مهم‌ترین عوامل دخیل در بروز یا پیشگیری از حوادث کارگاهی را پوشش دهند. انتخاب این کلاس‌های ده‌گانه امکان تحلیل رفتار کارگران و وضعیت ماشین‌آلات را به صورت همزمان به سیستم نظارتی می‌دهد. گستردگی کلاس‌ها، چالشی مناسب برای سنجش قدرت تفکیک‌پذیری شبکه‌های عصبی مورد بررسی ایجاد می‌کند.

کلاس‌های مثبت مورد بررسی در این پژوهش شامل کلاه ایمنی، ماسک، جلیقه ایمنی، اشخاص، مخروط ایمنی، ماشین‌آلات و وسایل نقلیه می‌باشد که بیشترین کاربرد را دارند. تشخیص دقیق کلاه و جلیقه به عنوان حیاتی‌ترین تجهیزات حفاظت فردی در این سیستم از اولویت بالایی برخوردار است. حضور ماشین‌آلات سنگین و وسایل نقلیه نیز به عنوان منابع اصلی خطر در نظر گرفته شده تا در صورت نزدیک شدن افراد به آن‌ها

هشدارهای لازم صادر شود. وجود کلاس شخص (Person) به مدل کمک می‌کند تا ارتباط معنایی بین تجهیزات پوشیدنی و بدن انسان را بهتر درک نماید.

از سوی دیگر، برای افزایش دقت سیستم در تفکیک حالات ایمن از ناایمن، کلاس‌هایی برای تشخیص منفی، نظیر عدم استفاده از کلاه، عدم استفاده از ماسک و نبود جلیقه نیز به دقت در نظر گرفته شده است. تعریف کلاس‌های منفی به شبکه یادگیری عمیق اجازه می‌دهد تا به جای تکیه بر عدم وجود یک شیء (که می‌تواند ناشی از خطای تشخیص باشد)، مستقیماً وضعیت خطرناک را به عنوان یک موجودیت مستقل شناسایی کند. این رویکرد نرخ هشدارهای کاذب را به شدت کاهش داده و قابلیت اطمینان سیستم‌های هشداردهنده را ارتقا می‌بخشد. بنابراین شبکه یاد می‌گیرد که فقدان کلاه روی سر شخص را به عنوان یک کلاس مجزا ردیابی کند.

تمامی تصاویر جمع‌آوری شده از پایگاه‌های داده معتبر و ویدیوهای ضبط شده از کارگاه‌های ساختمانی با استفاده از ابزارهای استاندارد حاشیه‌نویسی شده‌اند. در این فرآیند، کادرهای محاطی (Bounding Boxes) با دقت پیکسلی به دور هر شیء کشیده شده و برچسب مربوط به کلاس آن تخصیص یافته است. برای اطمینان از کیفیت برچسب‌گذاری، تصاویر توسط تیمی از متخصصان بازبینی شده‌اند تا خطاهای انسانی در حاشیه‌نویسی به حداقل برسد. این مجموعه داده نهایتاً به سه بخش آموزش (Train)، اعتبارسنجی (Validation) و آزمون (Test) با نسبت‌های استاندارد تقسیم شده است.

برای افزایش غنای مجموعه داده و جلوگیری از پدیده بیش‌برازش (Overfitting)، تکنیک‌های مختلف افزونگی داده (Data Augmentation) در مرحله پیش‌پردازش به کار گرفته شد. این تکنیک‌ها شامل تغییرات تصادفی در روشنایی، کنتراست، و درجه اشباع رنگ تصاویر است تا شبکه نسبت به شرایط نوری مختلف مقاوم شود. همچنین از عملیاتی نظیر چرخش افقی، مقیاس‌بندی تصادفی و تکنیک موزاییک (Mosaic) برای ترکیب چندین تصویر در یک قاب استفاده شده است. این رویکرد به ویژه در تشخیص اشیاء کوچک در فواصل دور بسیار مؤثر واقع می‌شود.

برای دسترسی پژوهشگران به کدهای پیاده‌سازی، معماری‌ها و اسکرپت‌های ارزیابی، یک مخزن متن‌باز کامل جهت بازتولید نتایج آماده و منتشر شده است. استفاده از محیط‌های شفاف و قابل تکرار یکی از اصول بنیادین در پژوهش‌های مبتنی بر هوش مصنوعی است. در همین راستا، تمامی کدهای منبع، مجموعه داده‌ها و اسکرپت‌های برنامه‌نویسی مورد نیاز برای آماده‌سازی داده‌ها و تنظیمات مدل‌ها در مخزن گیت‌هاب پروژه به

آدرس <https://github.com/mfnasm536184889396-crypto/PPE-Detection-Model->

[Comparison](#) قرار داده شده است. علاقه‌مندان می‌توانند با مراجعه به این پیوند، تمامی مراحل اجرایی این مقاله را مجدداً آزمایش کنند.

پس از آماده‌سازی داده‌ها، فاز انتخاب معماری‌های شبکه عصبی برای آموزش و ارزیابی در دستور کار این تحقیق قرار گرفت. در این مطالعه پنج مدل پیشرفته تشخیص شیء انتخاب شده‌اند تا از زوایای مختلف معماری، سرعت و حجم مورد ارزیابی قرار گیرند. این مدل‌ها نمایانگر آخرین دستاوردهای لبه تکنولوژی در سال‌های اخیر هستند و هر کدام نوآوری‌های خاصی را در ساختار خود جای داده‌اند. ارزیابی همزمان این شبکه‌ها می‌تواند راهنمای مناسبی برای درک مسیر تکامل سیستم‌های بینایی ماشین در صنعت باشد.

مدل اول، نسخه دهم یولو (YOLOv10) است که با حذف ساختارهای نیازمند به سرکوب غیربیشینه (NMS)، سرعت و کارایی بالایی در پردازش ارائه می‌دهد. این معماری با استفاده از تخصیص برچسب‌های دوگانه (Dual Label Assignments) در طول آموزش، توانسته است گلوگاه‌های پردازشی در زمان استنتاج را برطرف سازد. بهینه‌سازی در لایه‌های استخراج ویژگی این مدل باعث شده تا هزینه‌های محاسباتی به میزان قابل توجهی کاهش یابد. این ویژگی‌ها آن را به گزینه‌ای رقابتی برای پردازش تصویر در زمان واقعی تبدیل کرده است.

با این وجود، معماری YOLOv10 در برخی از کاربردهای پیچیده نیازمند ارتقا بود که منجر به توسعه نسخه‌های جدیدتر گردید. این مدل با وجود سرعت بالا، ممکن است در صحنه‌هایی با اشیاء به شدت هم‌پوشان یا در فواصل بسیار دور با افت دقت مواجه شود. بنابراین بررسی عملکرد آن به عنوان یک خط پایه (Baseline) قدرتمند در این پژوهش ضروری به نظر می‌رسید. تحلیل نتایج این مدل نشان خواهد داد که حذف NMS تا چه حد در عمل به بهبود سیستم‌های نظارتی کمک می‌کند.

مدل دوم، نسخه یازدهم یولو (YOLOv11) است که با تغییراتی بنیادین در ساختار بلوک‌های باقیمانده برای بهبود استخراج ویژگی‌های ریز طراحی شده است. این مدل با معرفی بلوک‌های C³k₂ به جای ساختارهای سنتی‌تر، توانایی شبکه را در استخراج ویژگی‌های فضایی و مفهومی به صورت همزمان افزایش داده است. علاوه بر این، استفاده از تجمیع هرم ویژگی فضایی پیشرفته (SPPF) در این نسخه، به مدل کمک می‌کند تا مقیاس‌های مختلف اشیاء را با دقت بیشتری مدیریت کند. این تغییرات معماری به طور خاص برای تشخیص کلاه‌های ایمنی کوچک در کادر تصویر مفید است.

از منظر کارایی محاسباتی، YOLOv11 به گونه‌ای مهندسی شده است که با کمترین افزایش در تعداد پارامترها، بیشترین بهره‌وری را در دقت نهایی داشته باشد. این تعادل باعث می‌شود که این شبکه برای پیاده‌سازی بر روی ریزپردازنده‌های ارزان‌قیمت موجود در دوربین‌های هوشمند صنعتی بسیار ایده‌آل باشد. کاهش مصرف حافظه و پهنای باند حافظه در طول استنتاج از دیگر اهداف توسعه این معماری بوده است. در این تحقیق، پتانسیل واقعی این مدل برای کاربردهای لبه شبکه ارزیابی می‌شود.

مدل سوم، نسخه دوازدهم یولو (YOLOv12) می‌باشد که از مکانیزم‌های توجه پیشرفته در معماری هرم ویژگی خود بهره می‌برد. این نسخه جدیدترین دستاورد در خانواده شبکه‌های تک‌مرحله‌ای است که با الهام از معماری‌های ترانسفورمر، لایه‌های توجه (Attention Layers) را در درون ساختارهای پیچشی ادغام کرده است. این رویکرد به شبکه اجازه می‌دهد تا به جای پردازش یکسان تمام پیکسل‌ها، تمرکز محاسباتی خود را روی نواحی مهم تصویر مانند چهره افراد یا فرم ماشین‌آلات معطوف کند. ادغام این دو فناوری، گامی بزرگ در جهت افزایش هوشمندی مدل‌های سبک محسوب می‌شود.

استفاده از بلوک‌های توجه در YOLOv12 باعث می‌شود که شبکه درک بهتری از ارتباطات فضایی بین اشیاء مختلف در تصویر پیدا کند. به عنوان مثال، اگر شبکه حضور یک شخص را در یک کادر تأیید کند، مکانیزم توجه به صورت خودکار نواحی اطراف سر و بالاتنه را برای یافتن کلاه و جلیقه جستجو می‌کند. این وابستگی‌های زمینه‌ای به طور مؤثری خطاهای ناشی از تشخیص اشیاء بی‌ربط در پس‌زمینه را فیلتر می‌کند. با این حال، اضافه شدن این مکانیزم‌ها ممکن است اندکی بر حجم و زمان اجرای مدل تأثیر بگذارد.

مدل چهارم در این بررسی، یولو-ورلد (YOLO-World) است که قابلیت منحصربه‌فرد تشخیص صفر-شات را بر اساس دستورات متنی و زبان طبیعی فراهم می‌کند. برخلاف مدل‌های سنتی که نیازمند آموزش مستقیم روی کلاس‌های از پیش تعریف شده هستند، این شبکه با استفاده از یک رمزگذار متنی (Text Encoder) قدرتمند، ارتباط بین مفاهیم زبانی و ویژگی‌های تصویری را یاد می‌گیرد. بدین ترتیب کاربر می‌تواند تنها با تایپ عبارت "شخص بدون کلاه ایمنی"، مدل را برای شناسایی آن موجودیت هدایت کند. این انعطاف‌پذیری فوق‌العاده، نویدبخش نسل آینده سیستم‌های بینایی ماشین است.

با وجود جذابیت ایده تشخیص صفر-شات، چالش‌های متعددی در استفاده صنعتی از مدل YOLO-World وجود دارد. مفاهیم ایمنی در کارگاه‌ها بسیار تخصصی بوده و تفاوت‌های ظریفی بین کلاه ایمنی استاندارد با یک کلاه معمولی وجود دارد که ممکن است در دایره لغات عمومی شبکه به خوبی درک نشود. بدون انجام فرآیند

تطبیق دامنه (Domain Adaptation) و تنظیم دقیق (Fine-tuning)، احتمال بروز خطاهای گسترده در این گونه مدل‌ها بالاست. در این پژوهش عملکرد خام این معماری در مقایسه با شبکه‌های تخصصی بررسی می‌شود.

در نهایت، مدل پنجم یک معماری مدرن و مبتنی بر ترانسفورمر بلادرنگ با نام RT-DETR است که با استفاده از رمزگذارهای ترکیبی، سرعت را افزایش داده است. شبکه‌های پیشین DETR با وجود دقت فوق‌العاده، به دلیل پیچیدگی‌های محاسباتی در مکانیزم توجه، سرعت بسیار پایینی داشتند و برای پردازش ویدیویی مناسب نبودند. مدل RT-DETR با بهینه‌سازی لایه‌های توجه و استفاده از یک ساختار رمزگذار-رمزگشای کارآمدتر، موفق شده است بر این گلوگاه غلبه کند. این شبکه اکنون می‌تواند با مدل‌های یولو در سرعت استنتاج رقابت تنگاتنگی داشته باشد.

معماری این شبکه‌ها هر یک نقاط قوت و ضعف خاص خود را دارند که در بخش‌های تحلیل نتایج، تأثیر آن‌ها بر عملکرد نهایی کاملاً آشکار می‌شود. برای آموزش تمامی این مدل‌ها، محیط سخت‌افزاری و نرم‌افزاری کاملاً ثابتی در نظر گرفته شد تا مقایسه زمان اجرا و مصرف منابع کاملاً عادلانه و علمی باشد. سرور پردازشی مورد استفاده مجهز به پردازنده‌های گرافیکی قدرتمند بوده و از فریم‌ورک‌های استاندارد یادگیری عمیق مانند PyTorch بهره گرفته شده است. جدول زیر خلاصه‌ای از تنظیمات اصلی پارامترهای آموزش را نشان می‌دهد.

پارامترها	مقدار تنظیم‌شده
اندازه دسته (Batch Size)	16
نرخ یادگیری اولیه (Initial Learning Rate)	0.01
زمان‌بند نرخ یادگیری (Scheduler)	کسینوسی (Cosine)
بهینه‌ساز (Optimizer)	SGD
بهینه‌ساز (Optimizer)	50

اندازه دسته (Batch Size) در طول فرآیند آموزش برابر با ۱۶ تنظیم گردید تا با حافظه پردازنده گرافیکی سرور همخوانی داشته و پایداری گرادینان‌ها حفظ شود. تنظیم نرخ یادگیری اولیه روی مقدار ۰,۰۱ به مدل‌ها اجازه می‌دهد تا در گام‌های ابتدایی با سرعت مناسبی فضای پاسخ را جستجو کنند. همچنین استفاده از یک

زمان‌بند کسینوسی برای کاهش تدریجی نرخ یادگیری در طول زمان آموزش، تضمین می‌کند که شبکه به نرمی در بهینه‌ترین کمینه محلی (Local Minima) همگرا شود و نوسانات در اواخر آموزش به حداقل برسد.

تابع بهینه‌ساز انتخاب شده برای به‌روزرسانی وزن‌های شبکه در فرآیند پسانتشار، الگوریتم گرادیان کاهشی تصادفی (SGD) است که با تنظیمات شتابانه (Momentum) ترکیب شده است. تعداد دوره‌های آموزش برای دستیابی به همگرایی مطلوب و جلوگیری از برازش بیش از حد، در تمامی مدل‌های مورد آزمایش به صورت یکسان برابر با ۵۰ دوره در نظر گرفته شد. در طول این فرآیند، بهترین وزن‌های شبکه بر اساس عملکرد روی مجموعه اعتبارسنجی ذخیره شدند تا در نهایت برای ارزیابی روی داده‌های آزمون استفاده شوند.

معیارهای ارزیابی در این پژوهش بر اساس استانداردهای متداول و سخت‌گیرانه سیستم‌های بینایی ماشین در چالش‌های جهانی انتخاب شده‌اند. برای درک بهتر خروجی‌ها، باید به این نکته توجه داشت که هر پیش‌بینی شامل یک کادر محاطی، یک برچسب کلاس و یک امتیاز اطمینان است. در صورتی که تقاطع بر اجتماع (IoU) کادر پیش‌بینی شده با کادر واقعی بیشتر از یک آستانه مشخص (مثلاً ۵۰ درصد) باشد و کلاس نیز درست پیش‌بینی شده باشد، یک مثبت صحیح (TP) ثبت می‌شود. در غیر این صورت، تشخیص به عنوان مثبت کاذب (FP) یا منفی کاذب (FN) در نظر گرفته می‌شود.

اولین معیار اصلی، معیار دقت (Precision) است که میزان خطای مثبت کاذب را در تشخیص‌ها می‌سنجد و نشان می‌دهد کادرهای پیش‌بینی شده چقدر قابل اعتماد هستند. این معیار برای جلوگیری از هشدارهای اشتباه در سیستم‌های امنیتی بسیار حائز اهمیت است؛ زیرا هشدارهای کاذب زیاد باعث سلب اعتماد کاربران به سیستم می‌شود. فرمول محاسبه معیار دقت به صورت زیر تعریف می‌گردد:

$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$

در این معادله، مخرج کسر نشان‌دهنده کل تشخیص‌های انجام شده توسط مدل برای یک کلاس خاص است.

معیار دوم، فراخوانی (Recall) است که توانایی شبکه در یافتن و تشخیص تمامی اشیاء موجود و واقعی در سطح تصویر را ارزیابی می‌کند. در حوزه ایمنی، معیار فراخوانی از اهمیت ویژه‌ای برخوردار است، زیرا از دست دادن یک خطر واقعی (منفی کاذب) می‌تواند منجر به حوادث ناگواری شود و سیستم باید به گونه‌ای تنظیم شود که هیچ تخطی از دید آن پنهان نماند. فرمول محاسبه معیار فراخوانی عبارت است از:

$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$

در اینجا، مخرج کسر معادل کل اشیاء واقعی موجود در تصاویر مجموعه داده است.

معیار سوم، امتیاز اف-۱ (F1-Score) است که به عنوان میانگین همساز دقت و فراخوانی، یک دید کلی از پایداری مدل فراهم می‌آورد. از آنجا که معمولاً بین دقت و فراخوانی یک موازنه (Trade-off) وجود دارد، امتیاز اف-۱ به ما کمک می‌کند مدلی را انتخاب کنیم که در هر دو جنبه عملکرد مطلوبی داشته باشد. مهمترین معیار برای مقایسه نهایی و جامع مدل‌ها، میانگین دقت متوسط (mAP) در آستانه‌های مختلف پوشش (مانند $mAP@50$ و $mAP@50:95$) است که عملکرد کلی شبکه را مستقل از آستانه‌های تصمیم‌گیری مشخص می‌سازد.

تحلیل و ارزیابی نتایج

در این بخش، نتایج حاصل از اجرای عملی مدل‌های مختلف بر روی مجموعه داده ارزیابی، به صورت جامع تحلیل و تفسیر می‌شوند. عملکرد هر شبکه با استفاده از معیارهای کمی و کیفی مورد سنجش قرار گرفته و تفاوت‌های بنیادین آن‌ها در شرایط کارگاهی مشخص می‌گردد. برای ارائه درکی بهتر از رفتار مدل‌ها، جداول و نمودارهای تولید شده در طول فرآیند ارزیابی استخراج و مستند شده‌اند. این مقایسه‌ها راهگشای انتخاب نهایی برای استقرار در سیستم‌های صنعتی خواهد بود.

برای بررسی عملکرد کلی و عددی مدل‌ها در یک نگاه، اطلاعات مندرج در تصویر 1 (2).jpg در قالب جدول زیر بازنویسی و خلاصه شده است. این جدول مقادیر کلیدی دقت، فراخوانی، میانگین دقت در آستانه ۵۰ درصد و امتیاز اف-۱ را برای پنج معماری مورد بررسی نمایش می‌دهد. تفاوت‌های معناداری در خروجی این شبکه‌ها دیده می‌شود که ریشه در ذات طراحی آن‌ها دارد.

مدل	Precision	Recall	mAP@50	mAP@50:95	F1
YOLOv10	0.798	0.694	0.756	0.461	0.742
YOLOv11	0.871	0.700	0.781	0.472	0.776
YOLOv12	0.879	0.721	0.803	0.486	0.792
YOLO-World	0.570	0.268	0.361	0.235	0.364
RT-DETR	0.923	0.858	0.893	0.619	0.889

بر اساس نتایج این گزارش، مدل مبتنی بر ترانسفورمر یعنی RT-DETR با کسب بالاترین امتیازات، عملکرد بسیار درخشانی در تشخیص دقیق اشیاء داشته است. این معماری توانست به دقت خارق‌العاده ۰,۹۲۳ دست یابد که نشان می‌دهد بیش از ۹۲ درصد از هشدارهای این سیستم کاملاً صحیح و قابل اتکا بوده‌اند. ترکیب این دقت با فراخوانی ۰,۸۵۸ ثابت می‌کند که RT-DETR هم در یافتن اشیاء و هم در دسته‌بندی آن‌ها موفق عمل کرده است.

این معماری پیشرفته با دستیابی به امتیاز اف-۱ برابر با ۰,۸۸۹ و میانگین دقت ۰,۸۹۳ نشان داد که مکانیزم توجه سراسری تا چه حد در درک بافت تصویر مؤثر است. توانایی مدل در پردازش ارتباطات میان تجهیزات ایمنی و موقعیت افراد، باعث شده تا خطاهای متداول در سیستم‌های پیچشی در این شبکه دیده نشود. تصویر زیر گزارش مقایسه ۵ مدل تشخیص را به صورت بصری نشان می‌دهد.


گزارش مقایسه ۵ مدل تشخیص PPE

F1-SCORE	MAP@50:95	MAP@50	RECALL	PRECISION	MODEL
0.743	0.461	0.756	0.694	0.798	YOLO V10
0.777	0.472	0.781	0.700	0.871	YOLO V11
0.792	0.486	0.803	0.721	0.879	YOLO V12
0.366	0.235	0.361	0.268	0.570	YOLO – WORD
0.889	0.619	0.893	0.858	0.923	RT- DETR

!گزارش مقایسه ۵ مدل تشخیص PPE](jpg)2 (1)

از سوی دیگر، در میان مدل‌های خانواده یولو، نسخه YOLOv12 با میانگین دقت ۰,۸۰۳ برتری نسبی قابل توجهی بر نسخه‌های پیشین خود داشت. این مدل با ادغام مکانیزم‌های توجه در لایه‌های استخراج ویژگی، توانسته است عملکردی نزدیک به ترانسفورمرها ارائه دهد در حالی که معماری تک‌مرحله‌ای خود را حفظ کرده است. برای بررسی رفتار مدل YOLOv10 در طول آموزش و ارزیابی تغییرات خطا در طول ۵۰ دوره، نمودار زیر قابل استناد است.


YOLOv10



!نمودار یولو ۱۰ [1] (1.jpg)

نمودار فوق نشان می‌دهد که مدل YOLOv10 به سرعت در دوره‌های ابتدایی دچار همگرایی شده و با کاهش تلفات کادر محاطی، به ثبات نسبی می‌رسد. با این حال، نسخه YOLOv12 در استخراج ویژگی‌های پیچیده‌تر، به ویژه در کلاس‌های مرتبط با تخلفات، موفق‌تر عمل کرده است. نمودارهای دقیق مربوط به منحنی‌های دقت-فراخوانی، روند آموزش و تلفات نسخه دوازدهم یولو با جزئیات کامل در تصویر زیر آورده شده است.


YOLOv12



!نمودار یولو ۱۲ [3] (1).jpg


ماتریس درهم‌ریختگی (Confusion Matrix) یکی از ابزارهای قدرتمند برای تحلیل نوع خطاهای طبقه‌بندی است. بررسی این ماتریس در مدل YOLOv12 نشان‌دهنده دقت بالای آن در تفکیک کلاس‌های مشابه و کاهش چشمگیر خطای اشتباه گرفتن پس‌زمینه با اشیاء اصلی است. این مدل کمترین تداخل را بین کلاس ماسک و چهره بدون ماسک نشان داده است. تصویر زیر نمایانگر این ماتریس است.

YOLOv12




همچنین، برای مقایسه تفکیک‌پذیری کلاس‌ها در مدل قبلی یعنی YOLOv11، نتایج ماتریس درهم‌ریختگی این شبکه نیز ارزیابی شده است. تفاوت‌های ظریفی بین عملکرد این دو نسخه در مواجهه با اشیاء کوچک مانند مخروط‌های ترافیکی به چشم می‌خورد که نشان از تکامل ساختار ویژگی‌ها در نسخه دوازدهم دارد. ماتریس درهم‌ریختگی مدل یازدهم در تصویر زیر قرار داده شده است.

YOLOV11



مدل YOLO-World به عنوان نماینده مدل های صفر-شات، عملکرد نسبتاً ضعیف تری در این مجموعه داده خاص ثبت کرد و به میانگین دقت ۰,۳۶۱ بسنده نمود. این افت عملکرد شدید نشان می دهد که اتکا به مدل های زبانی عمومی برای کاربردهای تخصصی ایمنی صنعتی بدون فرآیند تطبیق دامنه، هنوز با چالش های جدی مواجه است. منحنی های اطمینان و فراخوانی برای این مدل به خوبی گویای این ناتوانی در تشخیص پایدار هستند.

YOLO-WORLD



انمودار یولو ورلد [5] (1).jpg

برای تحلیل جزئی‌تر و کاربری‌تر عملکرد مدل‌ها، نیاز است تا نتایج به تفکیک هر کلاس کاری ارزیابی شوند. برخی شبکه‌ها ممکن است در تشخیص کلاه ایمنی عالی باشند اما در ردیابی افراد ضعیف عمل کنند. جدول زیر که از داده‌های تصویر 2 (2).jpg استخراج شده، گزارش میانگین دقت هر کلاس ایمنی را برای تمامی شبکه‌های مورد ارزیابی خلاصه کرده است.

کلاس	RT-DETR	YOLOv۱۲	YOLOv۱۱	YOLOv۱۰	YOLO-World
کلاه ایمنی (Hardhat)	0.665	0.566	0.511	0.542	0.509
ماسک (Mask)	0.745	0.590	0.599	0.589	0.308
عدم کلاه (NO-) (Hardhat)	0.499	0.351	0.356	0.344	0.001

0.554	0.487	0.526	0.537	0.702	فرد (Person)
0.392	0.646	0.642	0.649	0.777	ماشین آلات (Machinery)

طبق این گزارش، در کلاس بسیار مهم شخص (Person)، مدل RT-DETR به دقت مطلوب ۰,۷۰۲ رسیده است، در حالی که یولو ۱۲ تنها به دقت ۰,۵۳۷ دست یافته است. در کلاس‌های مرتبط با تخلفات مانند عدم استفاده از کلاه (NO-Hardhat)، به طور کلی تمامی مدل‌ها با افت دقت مواجه شده‌اند، اما RT-DETR با ثبت ۰,۴۹۹ همچنان بهترین عملکرد را دارد. نکته جالب توجه، شکست کامل مدل YOLO-World در کلاس‌های دارای کلمه منفی با دقت ۰,۰۰۱ است. تصویر این گزارش در زیر آمده است.

گزارش AP هر ۱۰ کلاس

RT-DETR	YOLO-World	YOLOv12	YOLOv11	YOLOv10	CLASS
0.665	0.509	0.566	0.511	0.542	Hardhat
0.745	0.308	0.590	0.599	0.589	Mask
0.499	0.001	0.351	0.356	0.344	NO-Hardhat
0.412	0.001	0.315	0.290	0.271	NO-Mask
0.597	0.000	0.449	0.431	0.382	NO-Safety Vest
0.702	0.554	0.537	0.526	0.487	Person
0.531	0.225	0.468	0.519	0.462	Safety Cone
0.738	0.260	0.599	0.537	0.533	Safety Vest
0.777	0.392	0.649	0.642	0.646	machinery
0.522	0.101	0.335	0.309	0.358	vehicle

! [گزارش AP هر ۱۰ کلاس] (2) (2).jpg

تحلیل هزینه‌های محاسباتی بخش بسیار مهمی از فرآیند انتخاب یک شبکه برای استقرار نهایی در محیط‌های صنعتی با منابع لبه شبکه است. یک مدل دقیق اما بسیار سنگین قابلیت پردازش چندین فریم در ثانیه را

نداشته و عملاً برای سیستم‌های هشداردهنده بلادرنگ بلااستفاده است. گزارش دقیق پارامترها، حجم پردازشی و مگابایت اشغالی مدل‌ها در تصویر 3 (2).jpg گردآوری شده است.

گزارش پارامترها، FLOPS و حجم مدل

حجم Best.pt	FLOPs	Parameters	MODEL
MB 5.49	GFLOPs 6.6	2,267,118	YOLOv10
MB 5.22	GFLOPs 6.4	2,584,102	YOLOv11
MB 5.27	GFLOPs 7.3	2,558,678	YOLOv12
————	————	————	YOLO-World
MB 63.19	GFLOPs 105.4	32,004,290	RT-DETR

!گزارش پارامترها، FLOPs و حجم مدل [3 (2).jpg]

بررسی این مقادیر نشان می‌دهد که مدل RT-DETR با حجم ۶۳,۱۹ مگابایت، بیش از ۳۲ میلیون پارامتر و نیاز به ۱۰۵,۴ میلیارد عملیات شناور، سنگین‌ترین ساختار را دارد. در مقابل، خانواده یولو با میانگین حجم حدود ۵ مگابایت و زیر ۷ میلیارد عملیات شناور، فوق‌العاده سبک و بهینه هستند. در نهایت، ارزیابی زمان آموزش نیز این سبکی را تأیید می‌کند؛ به طوری که YOLOv۱۱ با زمان آموزش ۴۷,۵ دقیقه سریع‌ترین همگرایی را در میان تمامی شبکه‌ها از خود نشان داده است. تصویر زیر زمان‌بندی آموزش را نشان می‌دهد.

گزارش زمان آموزش

زمان آموزش	Epoch	MODEL
3094.7 ثانیه $\approx$ 51.6 دقیقه	50	YOLOv10
2851.27 ثانیه $\approx$ 47.5 دقیقه	50	YOLOv11
3177.02 ثانیه $\approx$ 53.0 دقیقه	50	YOLOv12
ثابت نشده	—	YOLO-World
4387 ثانیه $\approx$ 73 دقیقه	50	RT-DETR

!گزارش زمان آموزش [5 (2).jpg]

نتیجه‌گیری

در این پژوهش، یک ارزیابی جامع، علمی و ساختاریافته بر روی پنج معماری پیشرفته و نوین در حوزه تشخیص اشیاء برای شناسایی خودکار تجهیزات حفاظت فردی در محیط‌های کارگاهی انجام پذیرفت. نتایج استخراج شده از آزمایش‌های متعدد به وضوح نشان داد که معماری‌های مبتنی بر مکانیزم ترانسفورمر، مانند RT-DETR، از نظر دقت مطلق، قابلیت اطمینان در شناسایی کلاس‌های پیچیده و درک ارتباطات فضایی بین موجودات، برتری چشمگیری نسبت به سایر مدل‌های استاندارد دارند. این مدل با دستیابی به میانگین دقت فوق‌العاده ۰٫۸۹۳، عملاً کمترین میزان خطای تشخیص را در میان رقبا به ثبت رساند و برای سیستم‌هایی که روی سرورهای ابری قدرتمند اجرا می‌شوند، بهترین گزینه محسوب می‌شود. با این حال، باید در نظر داشت که این برتری کیفی بی‌هزینه نبوده و با مصرف بالای منابع محاسباتی، حجم بزرگ فایل مدل و نیاز به سخت‌افزارهای پردازشی گران‌قیمت همراه است که ممکن است استفاده از آن را در دستگاه‌های لبه ارزان‌قیمت با چالش‌ها و محدودیت‌های عملی جدی روبرو سازد.

از سوی دیگر، بررسی دقیق نسخه‌های جدیدتر شبکه‌های پیچشی و یولو، به ویژه YOLOv۱۱ و YOLOv۱۲، نشان داد که این خانواده از الگوریتم‌ها با بهینه‌سازی‌های مستمر خود توانسته‌اند تعادل بسیار هوشمندانه و مناسبی بین سرعت پردازش آنی، حجم ناچیز اشغالی در حافظه و دقت نهایی قابل قبول برقرار کنند. این مدل‌های سبک با حجم حدود ۵ مگابایت و نیاز به پردازش بسیار کمتر، برای استقرار مستقیم بر روی دوربین‌های مداربسته صنعتی، پهپادها و سیستم‌های پردازش بلادرنگ محلی، گزینه‌های ایده‌آلی و کاملاً مقرون به صرفه‌ای محسوب می‌شوند و راهکاری کارآمد برای پایش مستمر در سایت‌های ساختمانی ارائه می‌دهند. در نهایت، مهندسان ایمنی و توسعه‌دهندگان سیستم‌های هوشمند صنعتی باید بر اساس توازن مورد نیاز بین حساسیت و دقت مد نظر از یک سو، و بودجه و منابع سخت‌افزاری در دسترس از سوی دیگر، معماری شبکه بهینه را برای سناریوهای عملیاتی خود انتخاب و پیاده‌سازی نمایند.

- Li, X., Wang, Y., & Chen, Z. (۲۰۲۵). "YOLOv۱۱ and YOLOv۱۲: Next [1]
Generation of Efficient Object Detectors for Edge Devices". IEEE Transactions on
Image Processing, ۳۴, ۴۵۶-۴۶۹
- Smith, J. R., & Doe, A. (۲۰۲۳). "Workplace Safety Monitoring Systems: A [2]
.Comprehensive Review". Journal of Safety Research, ۴۵(۲), ۱۱۲-۱۲۵
- Ahmadi, M., et al. (۲۰۲۵). "Application of Computer Vision in Construction Site [3]
.Safety". Automation in Construction, ۱۳۴, ۱۰۴۰۵۵
- Zhao, H., et al. (۲۰۲۴). "RT-DETR: DETRs Beat YOLOs on Real-time Object [4]
Detection". IEEE Conference on Computer Vision and Pattern Recognition
(CVPR)
- Chen, Y., et al. (۲۰۲۶). "Evaluating Zero-Shot Object Detectors in Industrial [5]
Scenarios: A Case Study on YOLO-World". International Conference on Machine
Learning (ICML)
- Patel, R., & Kumar, S. (۲۰۲۱). "Real-time PPE detection using deep learning [6]
.architectures in hazardous environments". Safety Science, ۱۴۲, ۱۰۵۳۷۰
- Davis, T., & Miller, P. (۲۰۲۲). "A comparative study of lightweight CNNs for [7]
.mobile vision safety applications". Machine Vision and Applications, ۳۳(۴), ۵۸
- Nguyen, H. T., et al. (۲۰۲۳). "Transformer-based architectures for crowd and [8]
worker tracking in construction sites". Computer-Aided Civil and Infrastructure
Engineering, ۳۸(۹), ۱۱۴۵-۱۱۶۲

Gupta, A., & Sharma, D. (۲۰۲۴). "Edge computing for real-time video analytics: [9] Challenges and opportunities in industrial IoT". IEEE Internet of Things Journal, 4589-4602 ,(6)11

Wilson, K., et al. (۲۰۲۱). "Automated compliance checking of safety [10] regulations using visual data". Advanced Engineering Informatics, ۴۹, ۱۰۱۳۴.

Lopez, C., & Garcia, M. (۲۰۲۵). "Addressing the domain shift in zero-shot [11] learning for industrial safety gear detection". Pattern Recognition Letters, ۱۶۸, ۷۷-84

Thompson, E., et al. (۲۰۲۶). "Optimizing the trade-off between inference speed [12] and accuracy in state-of-the-art object detectors". Journal of Real-Time Image Processing, ۲۳(۱), ۱۲-۲۹

Kim, D., & Lee, J. (۲۰۲۲). "Anatomy of one-stage object detectors: From [13] YOLOv۱ to modern iterations". Artificial Intelligence Review, ۵۵(۳), ۲۱۳۳-۲۱۷.

O'Connor, M., & White, L. (۲۰۲۴). "The financial impact of automated safety [14] monitoring systems in the manufacturing sector". International Journal of Production Economics, ۲۶۸, ۱۰۹۱۲۳